TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG-HCM

PHẦN 2: TÓM TẮT, SO SÁNH VÀ TÁI HIỆN HAI PAPER

Học thao tác robot từ video: MimicFunc và RIGVid

Người thực hiện:

Họ tên: Phan Thị Ngọc Linh

Bài báo 1: MimicFunc (CoRL 2025) · Bài báo 2: RIGVid (ICLR 2026)

01. So sánh hai paper

MimicFunc (CoRL 2025) và RIGVid (ICLR 2026)

1.1. Giới thiệu

Dạy robot thao tác bằng video hấp dẫn vì video dễ thu thập hơn dữ liệu teleoperation, vốn tốn công sức và cần chuyên môn.

Khoảng cách video – robot

Khác biệt về góc nhìn, hình thái và môi trường nên video không dùng trực tiếp cho robot được.

Hạn chế của bắt chước

Thường cần demo khớp sát bối cảnh thực thi, hoặc phải thích nghi riêng cho từng robot.

Paper 1 · MIMICFUNC

Học từ một video người rồi chuyển kỹ năng sang công cụ mới có cùng chức năng.

Paper 2 · RIGVID

Bỏ hẳn demo của người: robot làm theo video do mô hình sinh video tạo từ ảnh cảnh và câu lệnh.

1.2. Paper 1 – MimicFunc (CoRL 2025)

Một video RGB-D của người → công cụ mới cùng chức năng

Bài toán

Công cụ cùng chức năng có thể khác hẳn về hình dạng, kích thước, cấu trúc (intra-function variation), nên khớp theo hình học hoặc hình ảnh dễ thất bại.

Ý tưởng chính

Khớp theo chức năng, không theo hình dạng. Công cụ là function frame dựng từ 3 điểm: function point, grasp point, center point. Trích keypoint từ video người → chuyển sang công cụ mới → tối ưu quỹ đạo.

Kết quả và hạn chế

79,5% thành công với công cụ mới (DINOBot 57,5%); nhiệm vụ nhiều bước 76,0%. Cần RGB-D, chỉ một tay, thiếu phản hồi xúc giác. Lỗi chính: nắm vật 32,65%, sinh quỹ đạo 26,53%.

1.3. Paper 2 – RIGVid (ICLR 2026)

Ảnh cảnh + câu lệnh → video AI sinh → quỹ đạo cho robot

Bài toán

Rót nước, nâng nắp nồi, đặt spatula, quét rác chỉ từ video AI sinh, không cần demo vật lý hay teleoperation. Khó: video có thể sai lệnh, méo vật, phi vật lý.

Ý tưởng chính

Kling sinh video, VLM lọc video sai lệnh, ước lượng depth, theo dõi pose 6D của vật bằng FoundationPose; giả định vật được nắm chắc để đổi quỹ đạo vật thành quỹ đạo bàn kẹp.

Kết quả và hạn chế

Khoảng 85% (4 tác vụ, xArm7), tương đương video người thật; vượt ReKep (50%), Gen2Act (67,5%). Sinh video tốn tài nguyên, cần mesh dựng sẵn, lỗi chính là depth đơn mắt.

1.4. Bảng so sánh MimicFunc và RIGVid

Tiêu chí	MimicFunc	RIGVid
Nguồn video	1 video người thật (RGB-D)	Video AI sinh từ ảnh cảnh + lệnh
Tổng quát hóa	Sang công cụ mới cùng chức năng	Không; vật cố định mỗi task
Biểu diễn	3 keypoint → function frame	Pose 6D của vật thao tác
Cần mesh vật?	Không	Có (BundleSDF)
Quy mô đánh giá	25 task × 10 lần	4 task × 10 video
Kết quả paper	79,5% (công cụ mới)	khoảng 85% (4 task)
Lỗi chính	Nắm vật, sinh quỹ đạo	Monocular depth

Vì điều kiện đánh giá khác nhau nên không so sánh trực tiếp hai con số kết quả.

1.5. Điểm giống và điểm khác

Điểm giống

Cả hai không dùng dữ liệu robot hay teleoperation. Từ video, hệ thống trích biểu diễn có cấu trúc (function frame ở MimicFunc, pose 6D của vật ở RIGVid), chuyển thành quỹ đạo end-effector, và đều dựa vào VLM ở các khâu then chốt.

Điểm khác

MimicFunc cần một video người thật nhưng dùng lại cho nhiều công cụ. RIGVid không cần người làm mẫu vì video do mô hình sinh từ ảnh cảnh và câu lệnh, đổi lại phải sinh và lọc video cho từng cảnh, và gắn với vật có mesh dựng sẵn.

1.6. Vì sao biểu diễn khác nhau lại dẫn tới lỗi khác nhau?

MimicFunc

Trừu tượng hóa công cụ thành 3 keypoint nên vượt được khác biệt hình dạng, nhưng không mô hình hóa lực tiếp xúc và độ vững của cú nắm, nên lỗi dồn vào nắm vật và sinh quỹ đạo.

32,65%
lỗi nắm vật

26,53%
lỗi sinh quỹ đạo

RIGVid

Theo dõi pose đầy đủ của vật trên video không có depth thật, nên lỗi chủ yếu là depth đơn mắt: sai giá trị và nhấp nháy giữa các khung hình.

100%
video thật, depth thật

85%
video thật, depth ước lượng

1.7. Hai hướng bổ sung nhau thế nào?

RIGVid có thể giúp MimicFunc

MimicFunc cần RGB-D thật và tự nêu depth đơn mắt là hướng mở rộng cho video RGB. Đó chính là điểm yếu chính của RIGVid, nên hai bên có cùng một bài toán depth cần giải.

Ghép hai hướng

Video sinh của RIGVid có thể thay người làm mẫu, và function frame có thể giúp RIGVid sang vật khác. Chưa paper nào thử.

Đây là phần suy luận của em khi đọc 2 paper.

02. Paper 1 – MimicFunc

Bắt chước cách dùng dụng cụ từ một video người

2.1. Bài toán: 1 video người dùng cốc → robot dùng ấm



DEMO (mug → bowl)



TEST (teapot → bowl)

Trái: video demo (người rót bằng cốc). Phải: cảnh mới, dụng cụ khác hình dạng.

Làm sao tạo chuyển động rót cho ấm mà không quay thêm video?

2.2. Quy trình 3 giai đoạn của MimicFunc (3-Stage Pipeline)

Từ một video RGB-D của người → function frame → quỹ đạo 6-DoF cho robot

1

Giai đoạn 1: Trích xuất keypoint từ video

Functional Keypoint Extraction

Tự động phát hiện các khung hình mấu chốt (keyframe discovery) và trích xuất quỹ đạo 3D của 3 keypoint.

2

Giai đoạn 2: Thiết lập tương quan chức năng

Functional Correspondence Establishment

Chuyển giao keypoint sang đồ vật mới và căn chỉnh hệ tọa độ function frame.

3

Giai đoạn 3: Tạo hành động cho robot

Function Frame-Based Action Generation

Giải bài toán tối ưu hóa có ràng buộc để tạo quỹ đạo di chuyển 6-DoF thực tế cho robot.

2.3. Giai đoạn 1: Trích xuất keypoint từ video

Từ video người → function plan + quỹ đạo 3D của 3 keypoint: function, grasp, center



Phát hiện keyframe

Function plan gồm 3 keyframe: khởi đầu (t = 0), cầm nắm (t = t_g), tương tác chức năng (t = t_f), với 0 < t_g < t_f < N−1.

VideoCLIP so khớp khung hình với mô tả keyframe định sẵn.

Trích xuất 3 keypoint

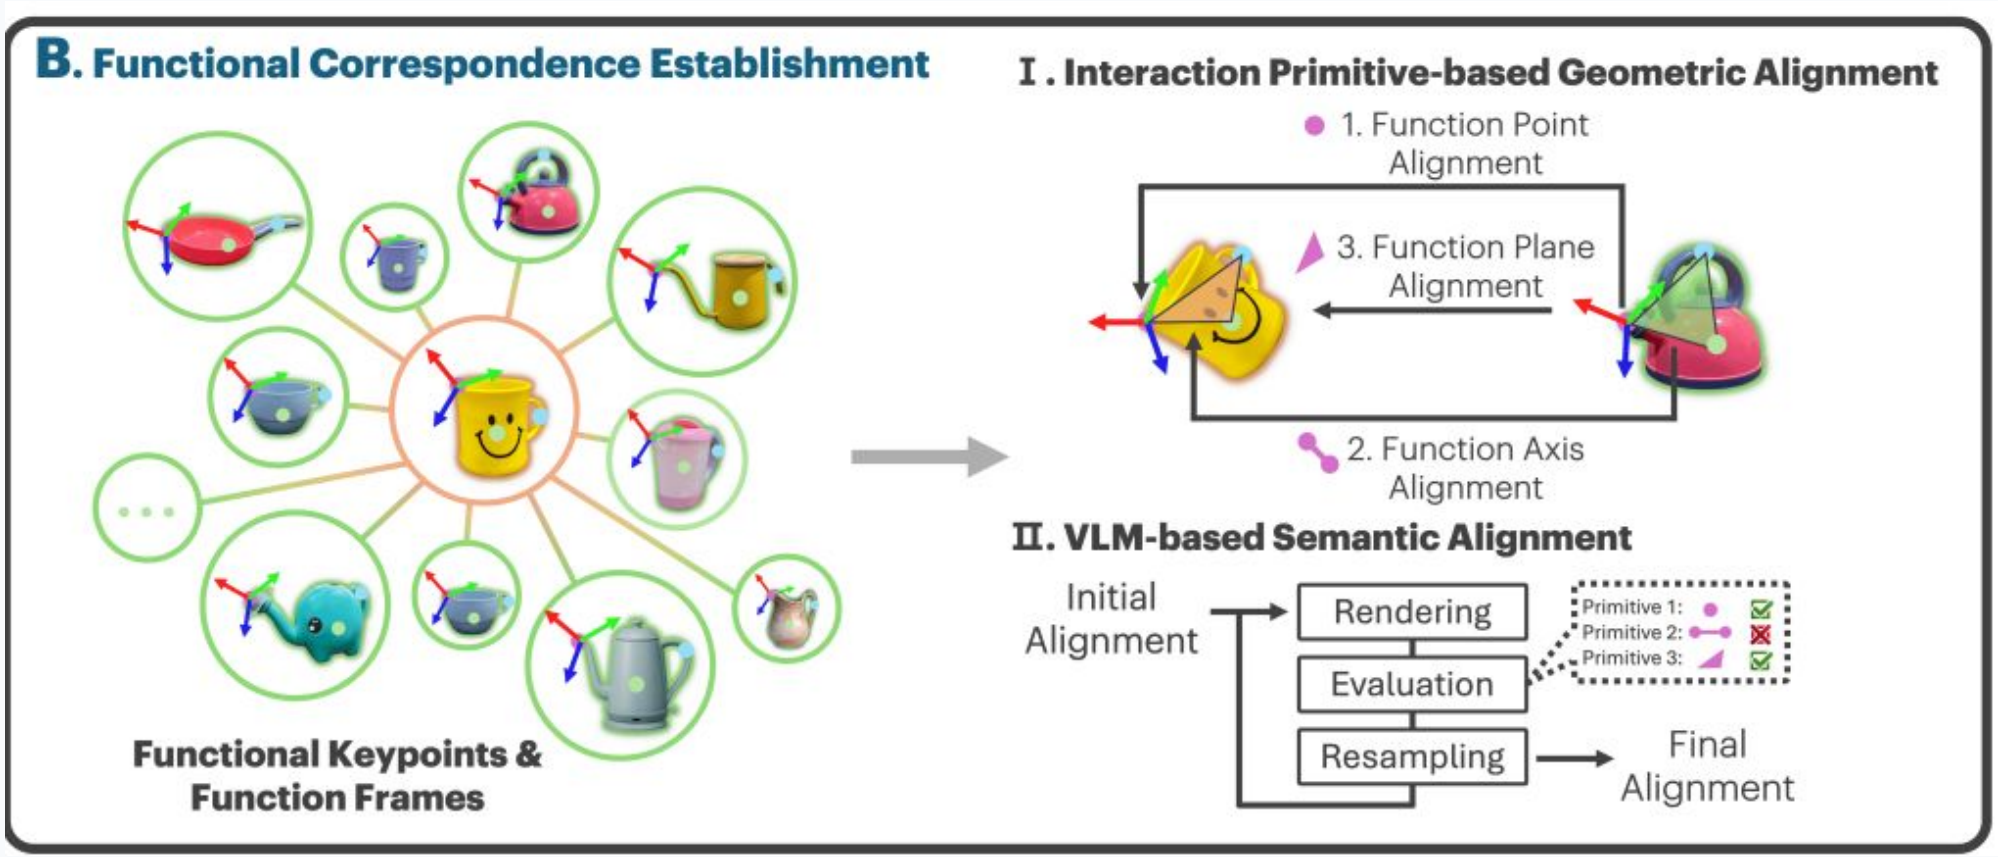
- **Grasp:** HaMeR dựng bàn tay 3D tại t_g; lấy tâm vùng giao giữa đầu ngón tay và dụng cụ.
- **Center:** tâm bounding box 3D của dụng cụ ở t = 0.
- **Function:** VLM + mark-based visual prompting tại t_f.

Theo dõi quỹ đạo 3D

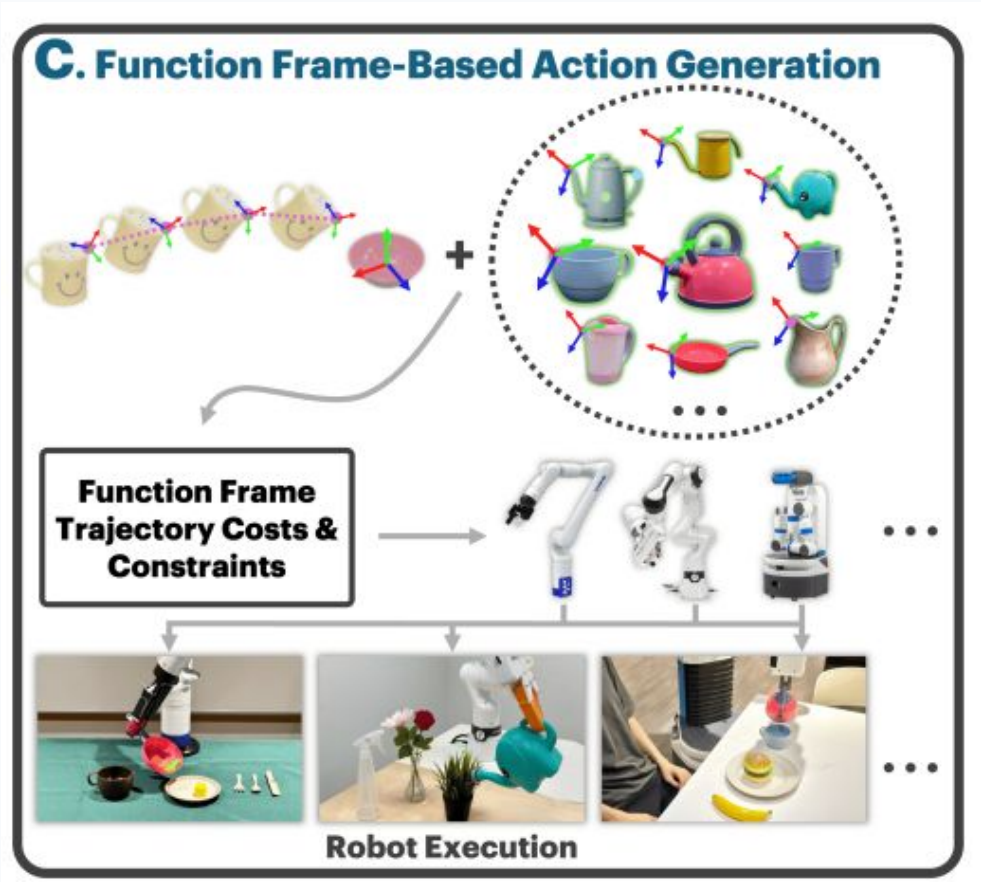
CoTracker ước lượng phép biến đổi tương đối của dụng cụ giữa các bước, từ đó suy ra quỹ đạo 3D của 3 keypoint.

Mọi tọa độ được quy về hệ tọa độ vật đích (target frame) nên không phụ thuộc vị trí tuyệt đối.

2.4. Giai đoạn 2: Chuyển keypoint và căn chỉnh function frame



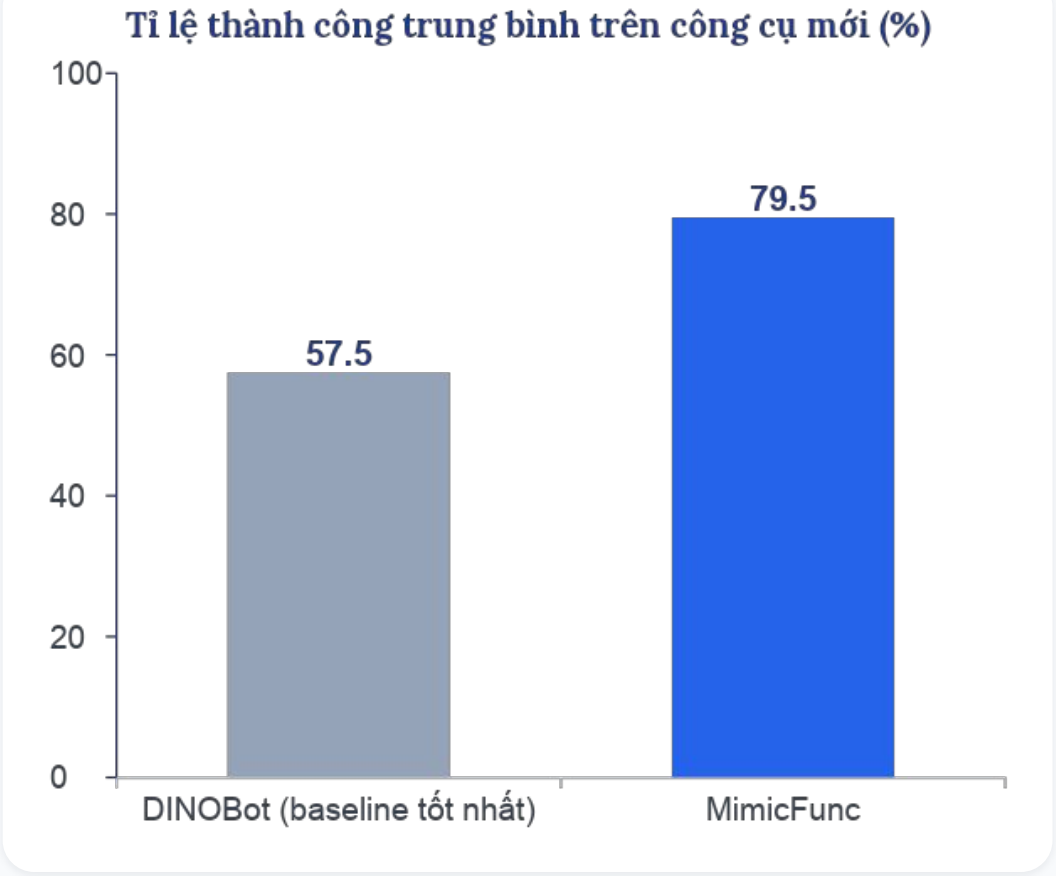
2.5. Giai đoạn 3: Tạo hành động cho robot





2.6. Kết quả thực nghiệm trên robot thực

video người hành động của người → thành công 79,5% trên công cụ mới, vượt xa các baseline



79,5%

thành công trên công cụ mới (DINOBot: 57,5%)

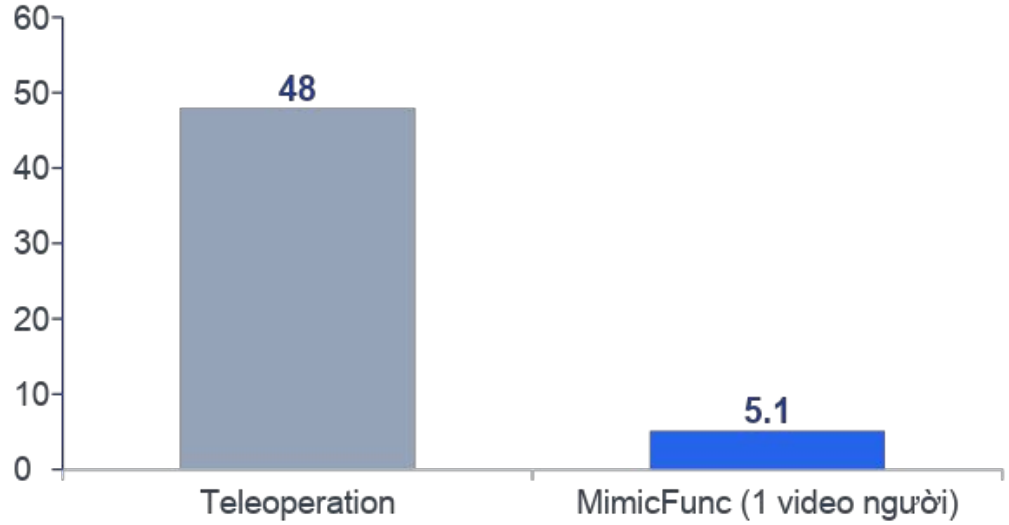
76,0%

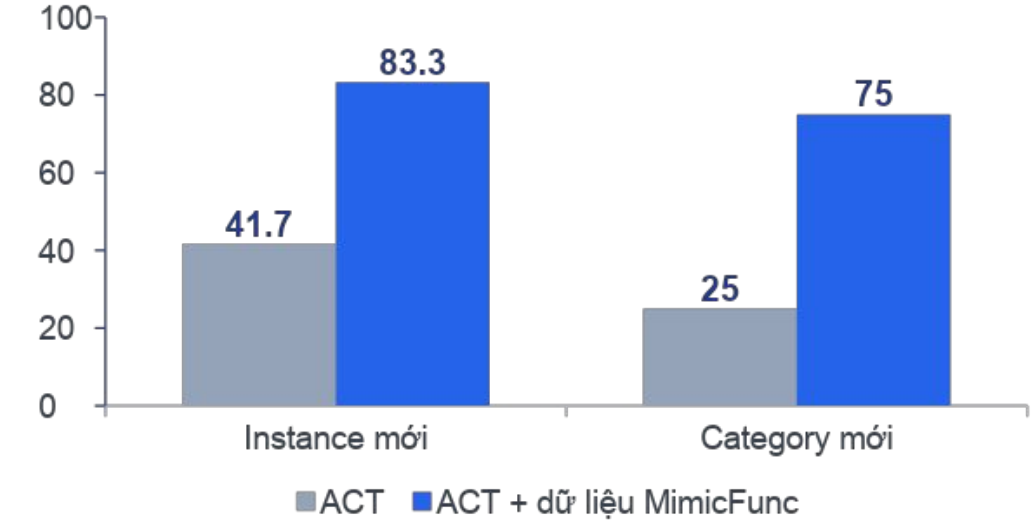
thành công với chuỗi nhiệm vụ dài (80,0% bước hoàn thành)

Thiết lập thử nghiệm

- 25 tác vụ = 5 chức năng (Pour, Cut, Scoop, Brush, Pound) × 5 công cụ; mỗi tác vụ chạy 10 lần.
- 3 mức tổng quát hóa: vị trí, instance mới, category mới.
- Baseline: DINOBot, DITTO, ORION; đều giảm 20-40% khi sang instance và category mới.
- Chuỗi dài: nút thắt là tầm với của tay máy đơn.

2.7. Ứng dụng: tự động khởi tạo dữ liệu huấn luyện





- **Tốc độ:** 5,1 giây/video so với 48 giây/demo teleoperation, nhanh hơn ≈ 9,4 lần.
- **Quy trình:** mỗi đối tượng mới có 30 rollout tự sinh từ 1 video người; chỉ giữ rollout thành công (VLM đánh giá) để huấn luyện.
- **Chất lượng dữ liệu:** ACT học từ 50 mẫu của MimicFunc đạt 53,85%, cao hơn 46,15% khi học từ teleoperation.

2.8. Hạn chế và hướng phát triển tương lai

MimicFunc tổng quát hóa theo chức năng, nhưng còn phụ thuộc cảm biến và phạm vi ứng dụng

Hạn chế hiện tại

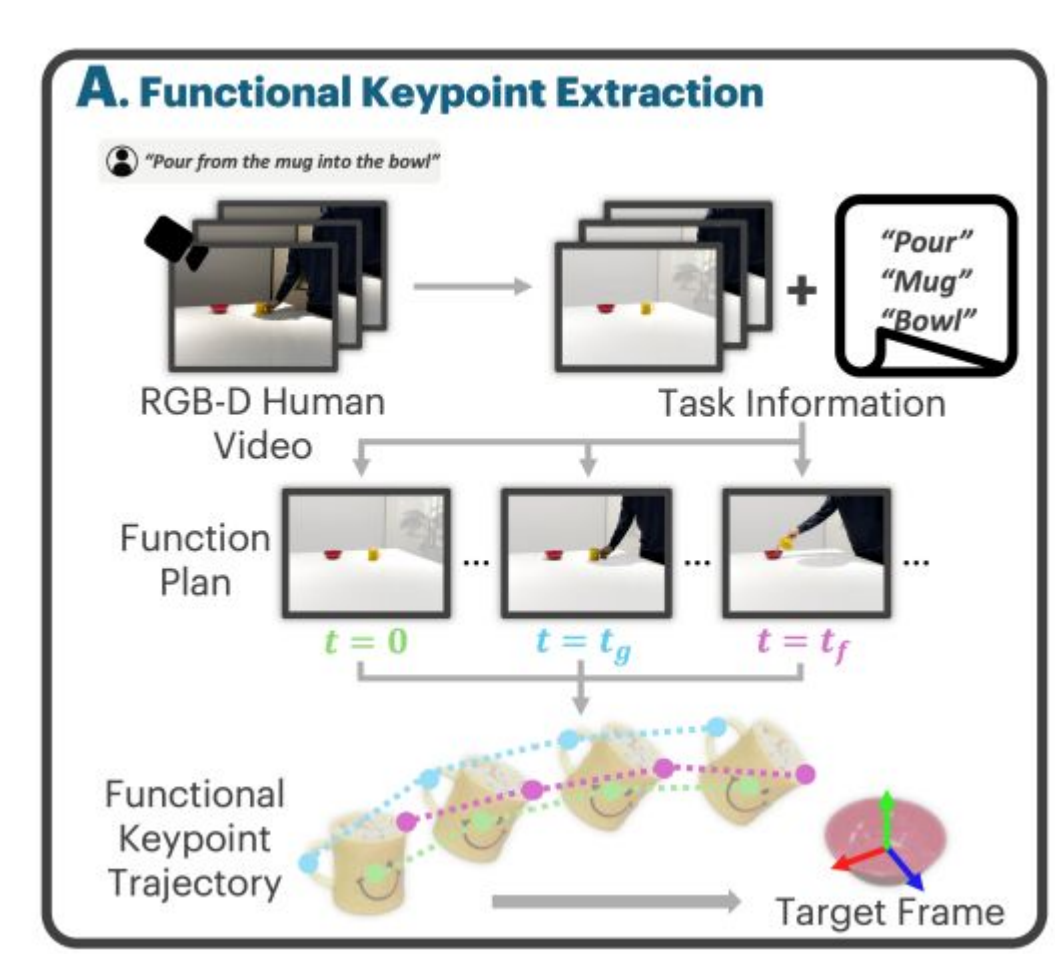
- **Phụ thuộc đầu vào RGB-D:** chưa dùng trực tiếp được video RGB thông thường trên Internet.
- **Mới áp dụng cho tay máy đơn (single-arm):** chưa xử lý thao tác cần phối hợp hai tay.
- **Phạm vi sinh dữ liệu còn hẹp:** mới thử huấn luyện visuomotor policy trên tác vụ Pour.

Hướng phát triển

- **Ước lượng độ sâu đơn thị giác:** tích hợp mô hình như Depth Anything để dùng video RGB từ Internet.
- **Phối hợp hai tay máy (bimanual):** mở rộng để thực hiện các thao tác phức tạp hơn.
- **Hệ thống sinh dữ liệu trong mô phỏng:** sinh dữ liệu đa dạng từ một demo người cho visuomotor policy.

2.9. Tái hiện – Giai đoạn 1: Functional Keypoint Extraction





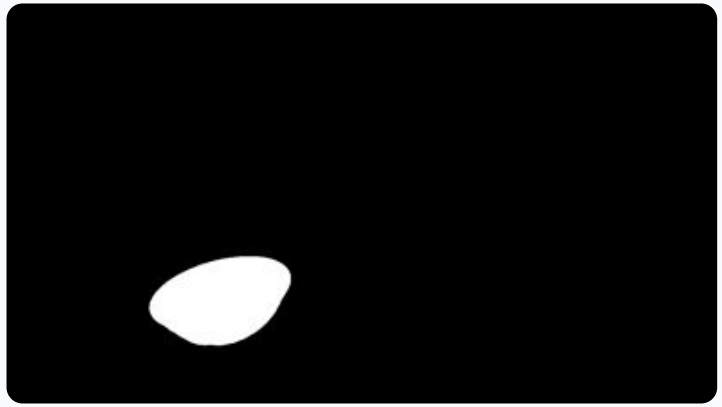
2.9.1 Tái hiện GĐ1 – Tìm vật và tách mask



Khung tool (ấm)



Mask tool



Mask target (tô)

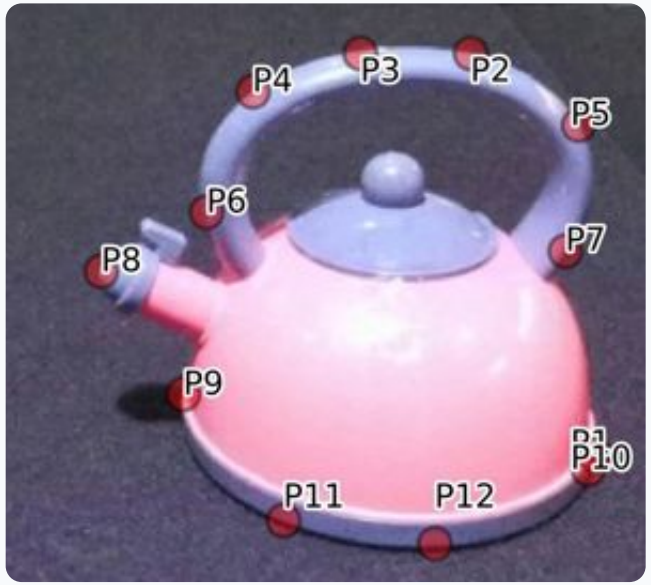
OWLv2 tìm vật theo tên chữ (“teapot”, “bowl”); SAM cắt đường viền.

Cần mask sạch để point cloud 3D không lẫn bàn/nền.

2.9.2 Tái hiện GĐ1 – Function point



Demo: điểm trên cốc



Ứng viên trên ấm



Điểm được chọn

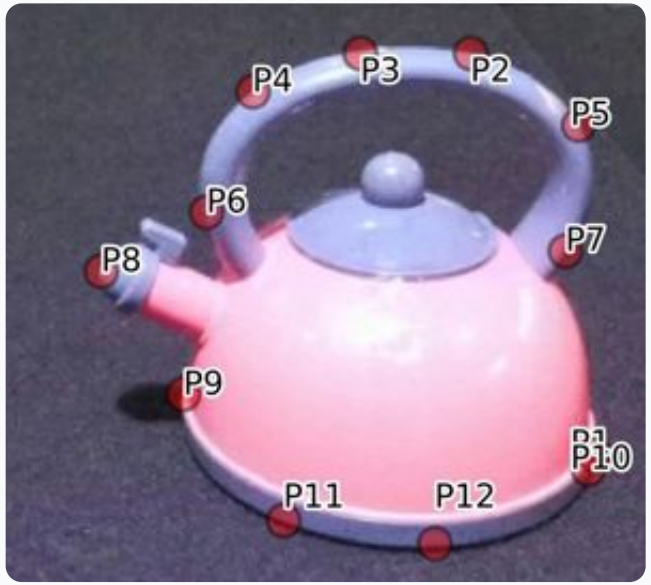
Đánh số ứng viên P1..Pk trên ấm, chọn điểm tương ứng với mép cốc ở demo.

Bài báo: VLM đề xuất vùng thô, rồi dense semantic correspondence chuyển điểm chính xác. **Tái lập: DINOv2 chọn điểm giống nhất.**

2.9.3 Tái hiện GĐ1 – Center point



Demo: chỗ cầm cốc



Ứng viên



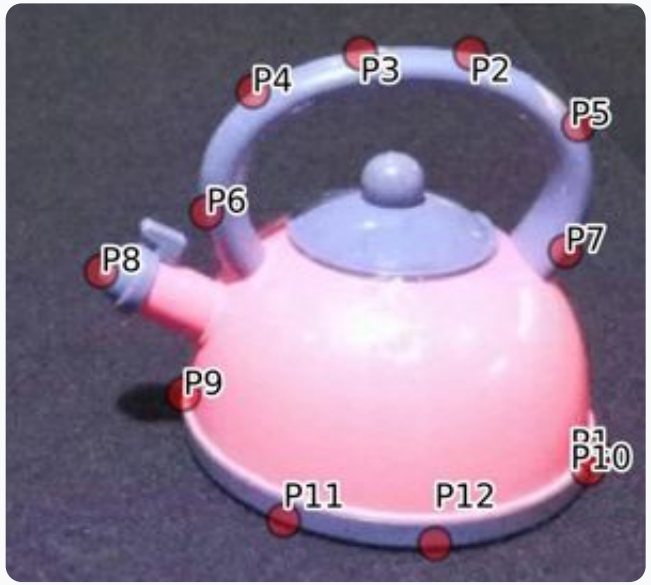
Được chọn

Theo paper, center point là tâm bounding box 3D của dụng cụ ở t = 0 (không do VLM chọn).

2.9.4 Tái hiện GĐ1 – Grasp point



Demo: chỗ cầm cốc



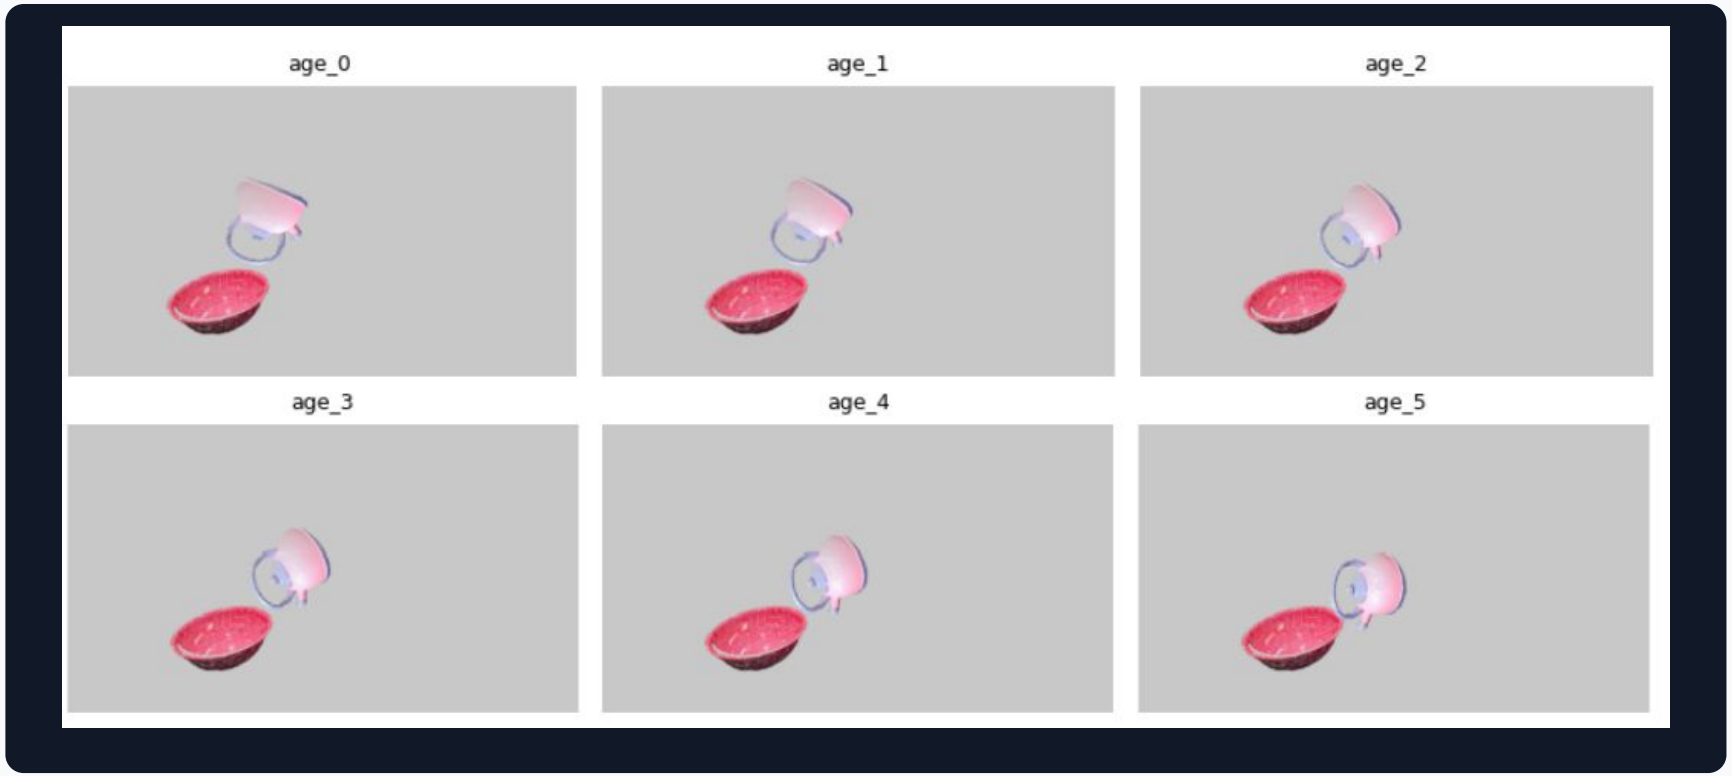
Ứng viên



Được chọn

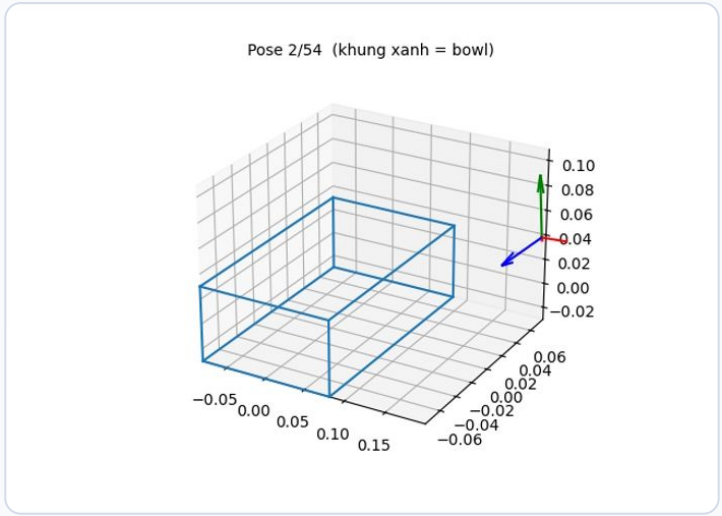
Cùng cách làm: biết cầm ở đâu thì mới đặt ấm đúng tư thế khi rót.

2.9.5 Tái hiện GĐ2 – Căn pose 3D của ấm

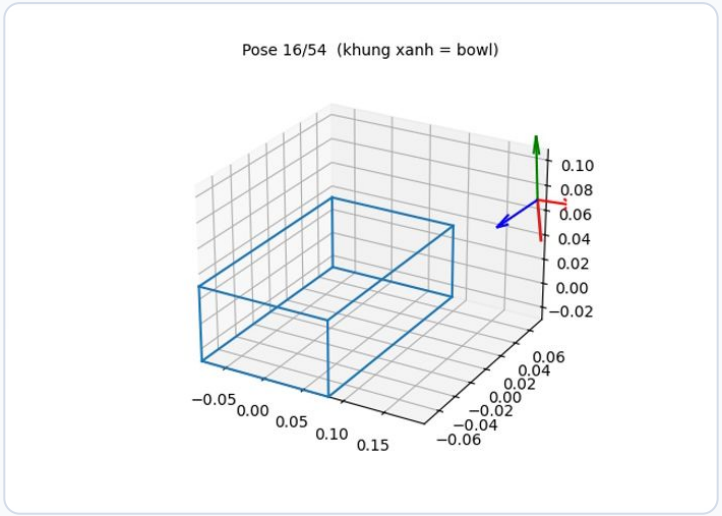


Nâng các điểm 2D lên 3D bằng ảnh độ sâu, thử nhiều hướng xoay
và chọn hướng làm 3 điểm của ấm khớp bố cục 3 điểm của cốc.

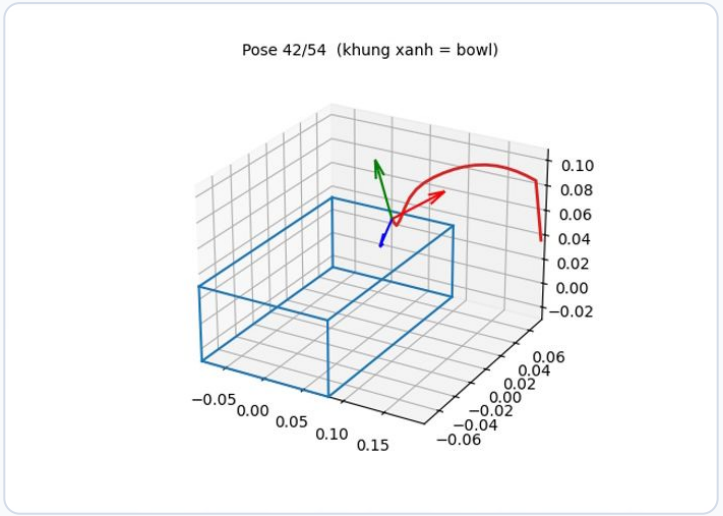
2.9.6 Tái hiện GĐ3 – Quỹ đạo tối ưu cho ấm



Pose 2/54: ấm đang đứng



Pose 16/54: ấm bắt đầu nghiêng



Pose 42/54: quỹ đạo tới gần tô

CasADi tối ưu 54 pose: bắt đầu đúng chỗ ấm đứng, đến pose rót thì vòi nằm trên tô,
và hình dạng chuyển động bám theo demo.

2.10. Kết quả tái lập

Chỉ số (abl_dino_k8_sam)	Kết quả
Mask IoU tool / target	0.952 / 0.994
Sai số function point	33.624 % đường chéo bbox
Sai số quỹ đạo	0.023 m, 36.170°
Pour proxy (đầu vòi nằm trên tô)	Đạt
Ablation: SAM thật vs hộp chữ nhật	8 ứng viên (Tối ưu nhất, sai số thấp hơn)

2.12. Các ca thất bại

Cấu hình lỗi

Cấu hình lỗi:

abl_dino_k8_box

abl_dino_k12_box

abl_dino_k16_box

Stage hỏng: tool_pose

Quan sát từ thực nghiệm

Chọn nhầm các điểm keypoint.







Dự đoán nguyên nhân

Vì khác hình dạng cốc/ấm, mask hình box.

Nên không thể xác định chính xác cấu trúc hình học không gian 3D của vật thể. Chọn nhầm điểm

2.13. Giới hạn của bản tái hiện và hướng khắc phục

Giới hạn

Chọn điểm phụ thuộc VLM, không ổn định, khó tự kiểm tra.

03. Paper 2 – RIGVid

Robot bắt chước các video được từ AI mà không cần video thật

3.1. Bài toán: ảnh cảnh + lệnh → robot thực thi

Đầu vào

Ảnh RGB-D của cảnh ban đầu

Câu lệnh hành động muốn thực hiện, ví dụ “pour water on the plant”

Video AI sinh ra

Kling (video diffusion) sinh video làm tác vụ

VLM lọc bỏ video sai lệnh

Đầu ra

Quỹ đạo 6-DoF của end-effector

Không demo vật lý, không teleoperation, không huấn luyện riêng cho robot

4 tác vụ đánh giá trong paper

Rót nước | **Nâng nắp nồi** | **Đặt spatula** | **Quét rác**

Câu hỏi: một video sinh ra, khớp đúng cảnh và lệnh, có thể là nguồn giám sát duy nhất cho thao tác robot không?

Thách thức: video thuần màu có thể sai lệnh, méo vật hoặc phi vật lý, vậy làm sao lấy ra quỹ đạo đủ chính xác?

3.2. Tổng quan 5 bước

1

Sinh và lọc video

Kling + VLM, thử tối đa 5 lần

2

Depth

depth đơn mắt, căn tỉ lệ theo khung đầu

3

Pose 6D

Grounding DINO + SAM-2, FoundationPose

4

Nắm vật

AnyGrasp, bàn kẹp đi theo vật

5

Thực thi

lệch 3 cm hoặc 20° thì lùi và chạy tiếp

Vì sao sinh video?

Video cho cả chuỗi chuyển động dày theo thời gian. VLM chỉ cho keypoint hay ràng buộc thưa (như ReKep), thiếu chi tiết để robot thực thi.

Vì sao theo dõi pose 6D của vật?

Pose 6D dùng toàn bộ hình học của vật nên vẫn ổn khi vật xoay mạnh hay bị che, còn point tracking mất dần điểm. Sang robot khác chỉ cần đổi một phép biến đổi.

Ý tưởng: lấy quỹ đạo pose 6D của vật đang được thao tác từ video sinh ra, rồi giả định vật được nắm chắc để biến nó thành quỹ đạo của bàn kẹp.

3.3. Bước 1 – Sinh video và lọc bằng VLM

Quy trình lọc video



Cách làm

- Kling sinh video từ ảnh cảnh và lệnh. Nền sạch, ít vật gây nhiễu và prompt ngắn cho video ổn định hơn.
- VLM trả lời Yes/No trên ảnh tóm tắt. Hỏng cả 5 lần thì vẫn dùng video lần cuối.
- Kling v1.6 qua lọc: rót 83%, nâng nắp 66%, đặt spatula 55%, quét 45%.
- Tương quan với đánh giá của người là 0,84. Bộ lọc hay bỏ nhầm video dùng được, hầu như không cho qua video sai.

3.4. Bước 2 – Ước lượng depth

Căn tỉ lệ depth

Video sinh: N khung RGB

↓

Mô hình depth cho $\hat{d}_t$ (chưa có đơn vị thật)

↓

$$d_t = s \cdot \hat{d}_t + b$$

(s, b) khớp depth khung đầu với depth thật quanh vật chủ động

↓

Depth theo mét cho cả video (dùng chung s, b)

Cách làm

- Depth đơn mắt không có đơn vị thật, chỉ đúng sai khác một phép co giãn và tịnh tiến.
- Xử lý: tính phép affine ở khung đầu, nơi có depth thật, rồi áp cho cả video.
- Lỗi sai giá trị: spatula tiến sát camera mà depth chỉ đổi 6,8 cm.
- Lỗi nhấp nháy: bình tưới gần như đứng yên mà depth đổi 1,9 cm trong 0,066 giây.
- Video thật cũng gặp hai lỗi này: giới hạn nằm ở mô hình depth.

3.5. Bước 3 – Theo dõi pose 6D của vật

Từ ảnh đầu đến pose 6D

GPT-4o chọn vật chủ động từ ảnh đầu và lệnh

↓

Grounding DINO cho hộp bao, SAM-2 tinh chỉnh thành mask

↓

FoundationPose: RGB + depth đã căn + mesh → pose 6D từng khung

↓

Làm mượt → quỹ đạo $T_{obj}(1...N) \in SE(3)$

Cách làm

- Vật chủ động là vật được tay thao tác. Mask ở khung đầu cũng cho biết nên nắm vật nào.
- FoundationPose theo dõi pose 6D, chạy real-time, không cần tinh chỉnh theo vật. Cần mesh dựng trước bằng BundleSDF.
- Ổn định hơn MegaPose: jitter tịnh tiến 0,0029 m so với 0,0045 m, jitter xoay 14,3° so với 37,5°.
- Làm mượt bằng trung bình trượt trên vị trí và vector quay.

3.6. Bước 4 – Nắm vật và quỹ đạo bàn kẹp

Từ quỹ đạo vật sang quỹ đạo bàn kẹp

Quỹ đạo vật (từ video)

$T_{obj}(1)$ $T_{obj}(2)$ $T_{obj}\dots$ $T_{obj}(N)$

Quỹ đạo bàn kẹp (end-effector)

$T_{ee}(1)$ $T_{ee}(2)$ $T_{ee}\dots$ $T_{ee}(N)$

$$T_{ee}(t) = T_{obj}(t) \cdot X^{-1}$$

X = pose của vật trong hệ end-effector, đo lúc nắm

Cách làm

- AnyGrasp chọn tư thế nắm có điểm cao nhất trong vùng quanh mask vật chủ động, rồi robot nắm vật.
- Giả định nắm chắc: X không đổi đến hết quỹ đạo. X gộp hai phép biến đổi cứng: pose vật so với bàn kẹp lúc nắm, và độ lệch bàn kẹp so với end-effector.
- Áp X lên từng pose của vật là ra pose end-effector tương ứng.
- Độc lập robot: đổi tay máy hay bàn kẹp chỉ cần cập nhật X.

3.7. Bước 5 – Thực thi và phục hồi khi lệch

Vòng lặp theo dõi và phục hồi

Theo dõi pose thực của vật bằng FoundationPose

↓

So với pose trên quỹ đạo kế hoạch

↓

Lệch quá 3 cm hoặc 20° không?

↓

Không → chạy tiếp theo quỹ đạo

Có → lùi về điểm cuối đã thực thi tốt, rồi chạy tiếp

Cách làm

- Khi chạy, robot liên tục theo dõi pose 6D của vật và so với quỹ đạo kế hoạch.
- Nếu lệch quá 3 cm về vị trí hoặc 20° về hướng, robot lùi về điểm cuối cùng đã thực thi tốt rồi chạy tiếp.
- Xử lý được cú đẩy giữa chừng, nắm lệch ban đầu và vật tuột khỏi bàn kẹp.
- Đánh giá trên xArm7 với camera Orbbec Femto Bolt, và chạy được trên ALOHA, kể cả hai tay.

3.8. Số liệu định lượng

Tác vụ	Chưa lọc (paper)	Sau lọc (paper)	Kết quả tái lập
Rót	80%	100%	[__]
Nâng nắp	60%	80%	[__]
Đặt spatula	50%	90%	[__]
Quét	20%	70%	[__]
Trung bình	52,5%	85%	[__]

Paper này em cài môi trường chưa được nên hong có kết quả tái lập.

Tham chiếu trong paper: video Sora 0%; ReKep 50%; Gen2Act 67,5%.

→ Thêm: tỉ lệ video qua lọc VLM, sai số pose, số lần phải lùi và chạy tiếp.

3.9. Ca thất bại

Cấu hình lỗi

Tác vụ / video lỗi: [__]

Bước hỏng: [__]

Quan sát

Video sai lệnh? Pose bị trôi? Depth nhấp nháy?

Nguyên nhân có thể

Video méo vật hoặc không làm theo lệnh, monocular depth sai giá trị.

3.10. Giới hạn của RIGVid

Theo paper

- Sinh video tốn nhiều tài nguyên
- Cần mesh vật dựng trước (không mesh: khoảng 30 phút mỗi video)
- Video sinh đôi khi không thực hiện lệnh
- Lỗi còn lại chủ yếu do monocular depth

4.1. Thuật ngữ chính

Video imitation

Robot học một việc bằng cách xem video của việc đó, thay vì điều khiển từ xa hay tự thử sai. MimicFunc dùng video người quay; RIGVid dùng video AI tự sinh.

Keypoint và Function frame

Keypoint là điểm đáng chú ý trên công cụ. MimicFunc dùng 3 điểm: function point (chỗ tác động lên vật), grasp point (chỗ nắm), center point (tâm). Function frame là hệ tọa độ dựng từ 3 điểm, gốc tại function point, để so khớp công cụ khác hình cùng chức năng.

Pose 6D và Tracking

Pose 6D là vị trí 3D cộng hướng xoay 3D của vật (6 bậc tự do). Tracking là theo dõi pose qua từng khung hình. RIGVid dùng FoundationPose để lấy quỹ đạo pose của vật.

Depth đơn mắt (monocular depth)

Ước lượng độ sâu chỉ từ ảnh hoặc video màu thường: rẻ nhưng có thể sai giá trị và nhấp nháy giữa các khung hình. Theo RIGVid, đây là nguồn lỗi chính.

4.2. Thuật ngữ xử lý và chỉ số đánh giá

Retargeting
Chuyển chuyển động quan sát được thành quỹ đạo cho bàn kẹp robot, giả định vật được nắm chắc nên phép biến đổi bàn kẹp–vật không đổi.

VLM
Mô hình hiểu cả ảnh và chữ. MimicFunc: đề xuất vùng điểm chức năng, đánh giá tư thế hợp lệ. RIGVid: lọc video sinh không đúng lệnh.

Closed-loop
Robot vừa chạy vừa đo lại pose của vật. Theo RIGVid, lệch hơn 3 cm hoặc 20° thì lùi về điểm thực thi tốt và chạy tiếp.

Chỉ số	Ý nghĩa	Tốt khi
AKD (pixel)	Khoảng cách trung bình giữa điểm dự đoán và điểm nhãn tay	Càng nhỏ
AP@15/30/45	Tỉ lệ điểm sai lệch không quá 15/30/45 pixel	Càng cao
Jitter RMS	Độ giật quỹ đạo: phần dư giữa quỹ đạo thô và bản đã làm mượt	Càng nhỏ
Pearson	Tương quan giữa điểm của bộ lọc và nhãn người	Càng gần 1
Success rate	Tỉ lệ lần thực hiện đạt điều kiện thành công	Càng cao